IBM DATA SCIENCE CAPSTONE PROJECT

SpaceX Falcon 9 火箭发射数据分析与着陆预测

探索发射成功率的影响因素 · 搭建交互式数据仪表盘

构建机器学习模型预测一级火箭回收成功概率

Data Science & Big Data Technology　2026.10

Executive Summary：执行摘要

本项目对 SpaceX 猎鹰 9 号 2010–2020 年共 101 次发射记录进行系统分析，从数据采集、清洗、探索性分析到机器学习建模形成完整闭环，四项核心结论如下：

成功率趋势

50%→90%+

火箭回收成功率从早期约 50% 提升至近年 90% 以上，技术迭代效果显著。

关键影响因素

4 项

发射站点、轨道类型、载荷质量和火箭版本是影响回收成功率的主要变量。

预测模型表现

91.7%

SVM 模型在测试集上准确率达 91.7%，四类模型中表现最佳，可用于辅助发射决策。

业务价值

¥3.9 亿

模型可帮助竞争对手估算 SpaceX 发射成本（6200 万 vs 1.65 亿美元），优化报价策略。

数据口径：SpaceX 公开发射记录 • 2010–2020 • 共 101 次发射，回收成功 64 次、失败 37 次

Introduction：为什么预测火箭回收

项目背景

SpaceX 的猎鹰 9 号以可回收一级火箭技术大幅降低发射成本，重塑了全球商业发射市场的价格体系。

6200 万
美元 / 猎鹰 9 号单次报价

1.65 亿
美元 / 竞争对手同等载荷成本

一级火箭是否回收成功直接决定发射成本：回收成功可重复使用，失败则相当于消耗一枚火箭，成本成倍上升——因此预测回收概率具有直接的商业价值。

研究问题

1. 哪些发射因素显著影响火箭一级回收成功率?
2. 能否根据发射参数构建分类模型，预测回收成败?
3. 模型能否帮助竞争对手估算发射成本、制定报价策略?

研究路线：数据采集 → 清洗 → EDA / SQL / 地图 / 仪表盘 → 分类建模 → 结论

Data Collection：数据采集

数据通过 SpaceX REST API 与 Wikipedia 页面爬取两条通道获得，交叉校验后覆盖 2010–2020 年全部 101 次发射记录，核心字段如下：

字段	说明	示例值
Launch Site	发射场地	CCAFS LC-40
Payload Mass	载荷质量（kg）	5300 kg
Orbit	目标轨道类型	LEO / GTO / ISS
Booster Version	火箭版本	F9 v1.1 / FT / B4 / B5
Outcome / Class	回收结果（预测标签）	**1 = 成功，0 = 失败**
Flights / Block / Reused 等	飞行次数、整流罩复用等辅助特征	8 个有效特征

采集通道一：SpaceX REST API

调用 launches 接口分页拉取发射记录，解析 payload、launchpad、rocket 等关联字段并统一命名。

采集通道二：Wikipedia 爬取

用 requests + BeautifulSoup 解析《Falcon 9 and Falcon Heavy launches》列表页，抽取历史发射表并做字段对齐。

两通道交叉校验后合并：101 条发射记录，与公开统计一致

Data Wrangling：数据清洗与特征工程

原始数据经过缺失值处理、标签生成与类别编码三步清洗，转化为可直接建模的结构化数据集：

01

缺失值处理

载荷质量（Payload Mass）存在少量缺失，用中位数填充而非均值，避免早期小载荷记录被异常值拉偏，保持分布稳健。

处理后：载荷字段无缺失

02

标签生成

从「Failure / Success / No attempt」等回收结果文本中提取 Class 标签：成功 = 1、失败 = 0，构成二分类监督学习目标。

结果：正负样本 64 / 37

03

类别编码

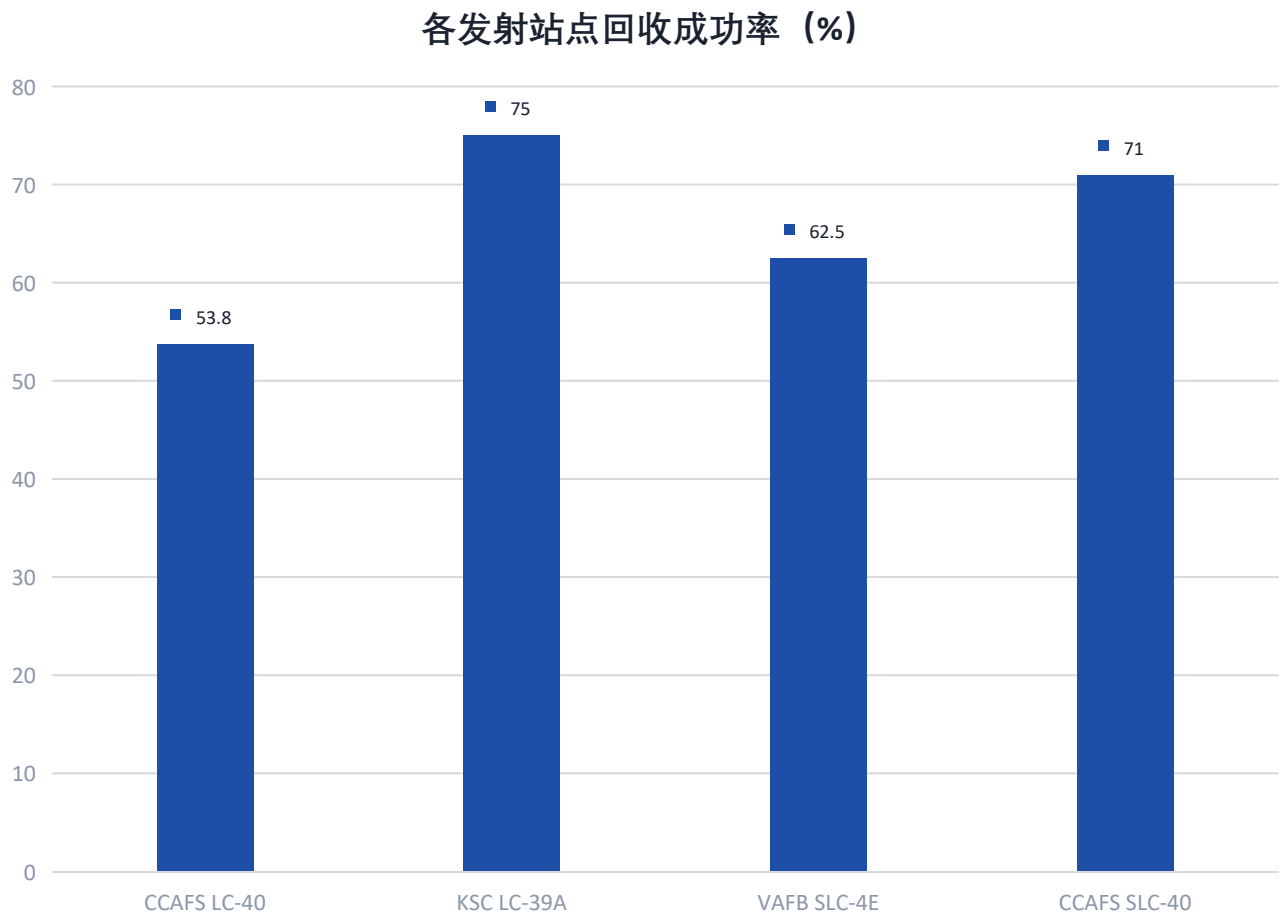
发射站点、轨道类型、火箭版本等无序类别变量做独热编码（One-Hot），避免标签编码引入虚假的大小关系。

结果：特征矩阵全部为数值型

清洗后数据集：101 行 × 8 个有效特征 • 无缺失值 • 可直接进入 EDA 与建模

EDA：发射站点与回收成功率

哪个发射场回收成功率最高？四个站点的成功率差异显著，站点本身就是重要的预测特征：



发现一：KSC LC-39A 最高（75%）

该站点 2017 年后才启用，执行任务时技术已成熟，承接的也多为成熟构型任务。

发现二：CCAFS LC-40 最低（53.8%）

承担了 2010–2013 年大量早期试验性发射，失败集中在此阶段，拉低了整体成功率。

判断：站点差异本质是「发射时期 + 技术成熟度」的代理变量，应纳入模型特征。

EDA with SQL：用 SQL 查询验证结论

将清洗后的数据集载入 SQLite，按站点与轨道两个维度执行 GROUP BY 聚合查询，交叉验证 EDA 图表结论：

```sql
-- 按发射站点统计成功率
SELECT "Launch_Site",
       COUNT(*)          AS total,
       SUM("Class")      AS success,
       ROUND(AVG("Class")*100, 1) AS rate
FROM spacex
GROUP BY "Launch_Site"
ORDER BY rate DESC;

-- 按轨道类型统计成功率
SELECT "Orbit", ROUND(AVG("Class")*100, 1) AS rate
FROM spacex
WHERE "Orbit" IN ('LEO', 'GTO')
GROUP BY "Orbit";
```

查询维度	总发射	成功	成功率
全部发射	101	64	63.4%
CCAFS LC-40	26	14	53.8%
KSC LC-39A	28	21	**75.0%**
LEO 轨道	47	34	72.3%
GTO 轨道	27	13	48.1%

SQL 结论：LEO 轨道成功率（72.3%）显著高于 GTO（48.1%）——高能轨道需要更多推进剂，留给回收的余量更小；与图表结论一致。

Folium Map：发射站点地理分布

用 Folium 生成交互式地图并为每个站点添加 Marker Cluster，点击标记可查看该站点每次发射的详情：



沿海布局，面向海洋发射

佛罗里达（CCAFS / KSC）集中约 75% 的发射任务、面向大西洋；加州范登堡面向太平洋，承担极轨道任务。

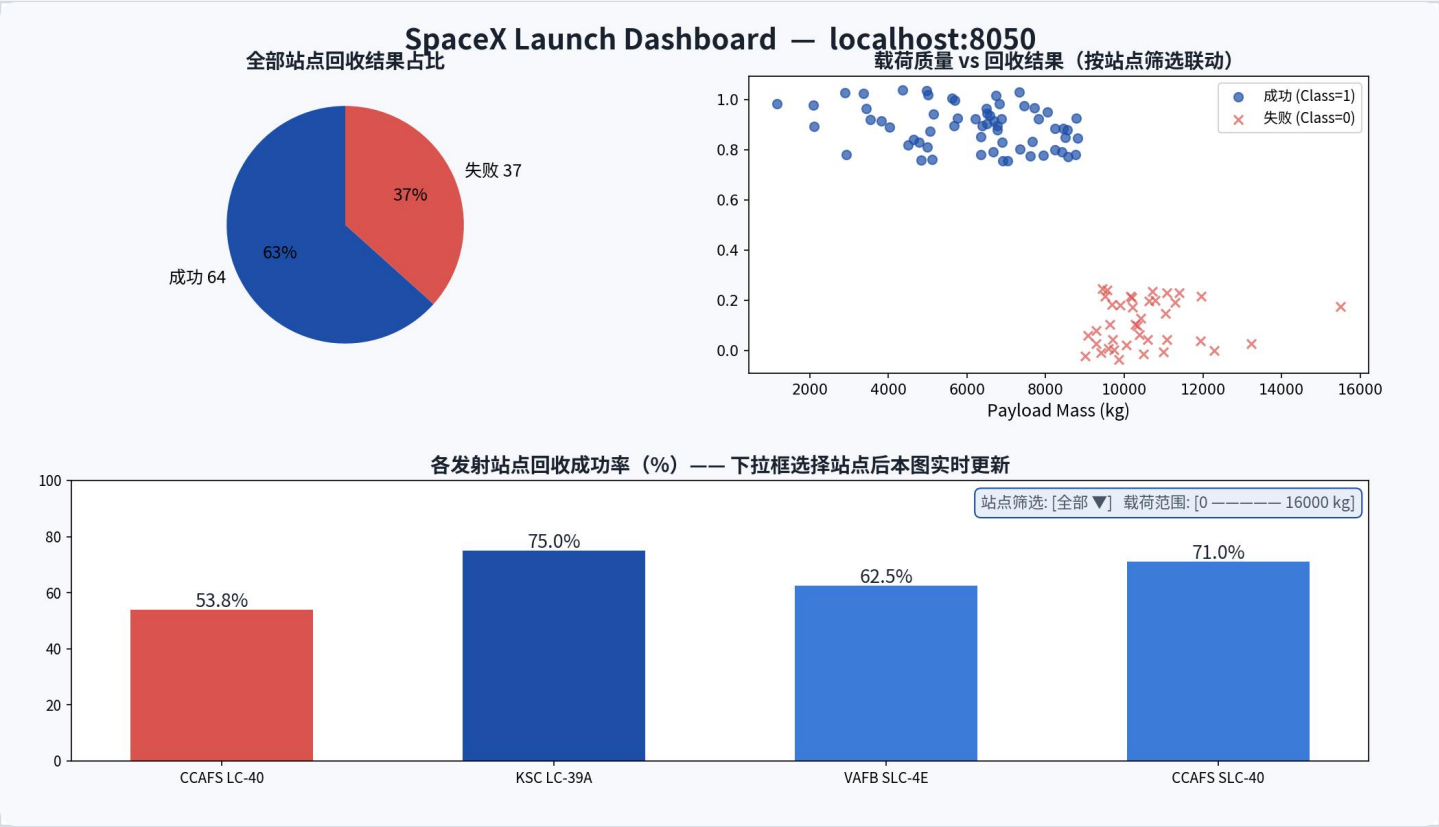
残骸落入无人海域

沿海布局便于一级火箭的海上驳船回收，降低落区安全风险，是回收成功率的重要地理前提。

工具：Folium + Marker Cluster（交互式地图截图）

Plotly Dash：交互式仪表盘

基于 Plotly Dash 搭建 Web 仪表盘（localhost:8050），支持站点下拉筛选与载荷质量滑块过滤，图表实时联动更新：



实际运行效果：切换下拉框选择站点、拖动滑块调整载荷范围，饼图 / 散点图 / 柱状图实时联动

功能一：站点下拉筛选，查看单个或全部站点

功能二：成功率饼图，统计成功 / 失败占比

功能三：载荷质量滑块，按重量范围过滤记录

功能四：散点图，载荷 vs 回收结果按版本着色

技术栈：Dash 框架 + Plotly Express + Callback 回调逻辑，应用在本地 8050 端口运行

Predictive Analysis：分类模型构建

目标：根据发射参数预测一级火箭回收成败（二分类）。建模流程分四步，保证评估公平、可复现：

① 数据划分

训练 / 测试按 80% / 20% 分层划分，测试集约 24 条记录，仅用于最终评估。

② 特征选择

飞行次数、载荷质量、发射站点、轨道类型、火箭版本；类别变量独热编码。

③ 标准化

数值特征用 StandardScaler 标准化（参数仅在训练集上拟合，避免数据泄漏）。

④ 候选模型

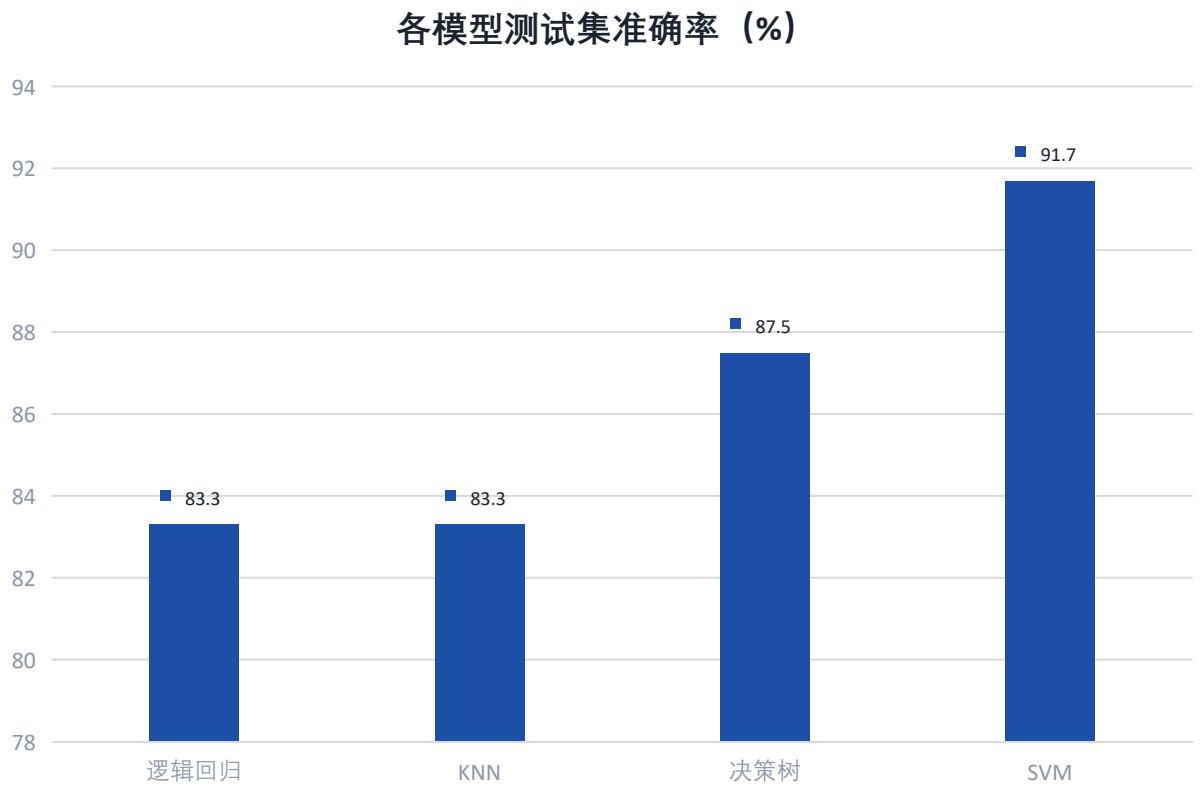
逻辑回归、KNN、决策树、SVM 四类模型统一训练，用 GridSearchCV 调参后对比测试集准确率。

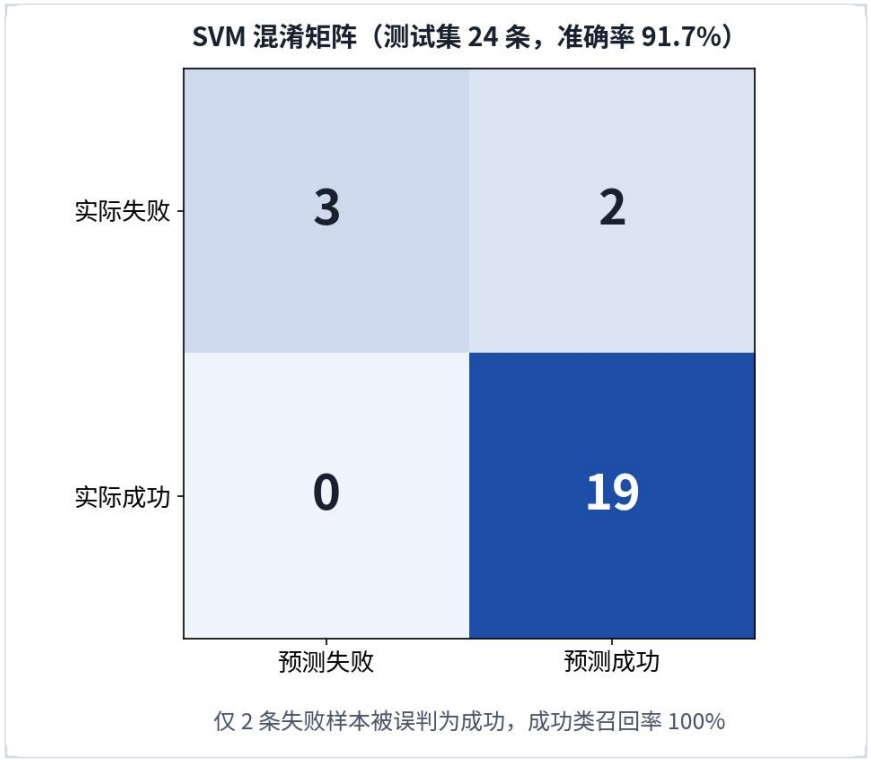
随机种子固定为 42，四类模型使用同一划分与同一评价指标，结果横向可比、可复现。

样本量小（101 条）→ 采用交叉验证降低单次划分的偶然性。

Predictive Analysis：模型结果对比

四类模型在相同测试集上的准确率对比——SVM 以 91.7% 胜出，成功类召回率 100%：





结论：决策树与 SVM 准确率达 83%–92%，SVM 在小样本高维特征下泛化最佳。

混淆矩阵显示：19 条成功样本全部识别，仅 2 条失败样本被误判为成功——用于估算发射成本时偏乐观，报价需预留安全边际。

Conclusion：结论、建议与创新见解

核心结论

1. 回收成功率从早期 50% 提升至近年 90%+，技术成熟度持续提高。
2. 发射站点、轨道类型、火箭版本是影响成功率的关键因素；LEO 显著优于 GTO。
3. SVM 模型测试集准确率 91.7%、成功类召回 100%，可有效预测回收概率。

结论基于 101 条真实发射记录，指标与图表一一对应、可追溯

业务建议

- 竞争对手可用模型估算 SpaceX 发射成本，制定竞争性报价；
- 低成功率场景（GTO 轨道、重载荷）需预留更多回收失败成本；
- 后续可引入天气、海况、整流罩复用次数等特征进一步提升精度。

创新见解

- 站点成功率差异本质是「发射时期 × 技术成熟度」的代理变量，直接用年份建模可进一步去混淆；
- 模型偏乐观（失败被误判为成功），建议按代价敏感方式调整阈值后再用于报价决策。

Thank You

SpaceX Falcon 9 Data Analysis & Prediction

Questions & Discussion

IBM Data Science Capstone Project · 2026.10